Instalación y uso
de los lenguajes **Julia**, Python y R
y entornos

RStudio JupyterLab

en *la nube* Google Cloud

## Introducción

El presente documento es un instructivo para instalar la última versión de Julia, Python, R, RStudio Server y Jupyter Lab sobre Ubuntu 22.04 LTS minimal en el entorno Google Cloud corriendo sobre una máquina virtual *spot* que representa el costo más bajo de todas las opciones disponibles en la nube a marzo-2024 para el tipo de procesamiento de generación de modelos predictivos.

## Las principales "nubes" son :

Amazon AWS EC2 <a href="https://aws.amazon.com/ec2/instance-types/">https://aws.amazon.com/ec2/instance-types/</a>

Microsoft Azure <a href="https://azure.microsoft.com/en-us/services/virtual-machines/">https://azure.microsoft.com/en-us/services/virtual-machines/</a>

Google Cloud <a href="https://cloud.google.com/compute/docs/instances/">https://cloud.google.com/compute/docs/instances/</a> <a href="https://www.alibabacloud.com/product/computing">https://www.alibabacloud.com/product/computing</a>

IBM Cloud <a href="https://www.ibm.com/cloud/virtual-servers">https://www.ibm.com/cloud/virtual-servers</a>
Oracle Cloud <a href="https://www.oracle.com/cloud/compute/">https://www.oracle.com/cloud/compute/</a>

Digital Ocean <a href="https://www.digitalocean.com/products/droplets/">https://www.digitalocean.com/products/droplets/</a>

Google Cloud provee máquinas virtuales comunes, y a un precio que en promedio se reduce entre 4 y 5 veces las máquinas virtuales llamadas *spot* <a href="https://cloud.google.com/compute/pricing">https://cloud.google.com/compute/pricing</a>.

Una máquina virtual *spot* <a href="https://cloud.google.com/compute/docs/instances/spot">https://cloud.google.com/compute/docs/instances/spot</a>, puede ser apagada por Google en cualquier momento. Esas máquinas spot pueden crearse y viven en la medida que Google tenga poder de cómputo ocioso en el datacenter donde está corriendo esa maquina virtual, cosa que suele suceder a la madrugada de ese datacenter, o los fines de semana.

Tenga en cuenta que lo más probable es que Google le mate su máquina *spot* cada 8/10 horas. Esto le demandará estar muy atento, verificando periódicamente cuales máquinas virtuales le han apagado. <u>No subestime lo dicho en este párrafo</u>.

Se puede ver las locaciones de los datacenters en <a href="https://cloud.google.com/compute/docs/regions-zones/regions-zones">https://cloud.google.com/compute/docs/regions-zones/regions-zones</a> y una aplicación que muestra en tiempo real el día y la noche es <a href="https://www.timeanddate.com/worldclock/sunearth.html">https://www.timeanddate.com/worldclock/sunearth.html</a>

Vale la pena leer esta documentacion <a href="https://cloud.google.com/compute/docs/concepts">https://cloud.google.com/compute/docs/concepts</a>
Los alumnos más técnicos podrian leer sobre esta alternativa <a href="https://blog.codinghorror.com/the-cloud-is-just-someone-elses-computer/">https://blog.codinghorror.com/the-cloud-is-just-someone-elses-computer/</a>

Se recomienda enfáticamente que configure el idioma inglés en Google Cloud durante toda la instalación, ya que la versión en español de Google Cloud es, al menos ... ambigua.

Esta es la razón por la cual se elige usar máquinas virtuales con sistema operativo Linux de tipo spot:

Google Cloud, costo por hora en <u>dólares</u> ( al 2024-03-11 )					
maquina virtual N1 de 16 vCPU y 104 GB de RAM, 256GB HDD us-west4 (Las Vegas)					
	Linux			Windows	
	Ubuntu	SUSE	Red Hat	Williaows	
Spot (mortal)	0.18	0.18	0.29	0.89	
Normal (inmortal)	0.78	0.78	0.89	1.50	

Crear las spot virtual machines en Las Vegas hace una gran diferencia de costo!

## Conceptualmente

- Todos los archivos que tomemos como input o generemos como output estarán siempre en el Google Storage Bucket , piénselo como un disco de red.
- En la imagen será donde están guardados el lenguaje R, todos sus paquetes, RStudio, el lenguaje Python, el lenguaje Julia, Jupyter Lab, etc
- Para cada proceso que corramos, crearemos una nueva máquina virtual, a partir de la imagen, procesaremos y eliminaremos la máquina virtual.
- Estaremos corriendo máquinas virtuales spot, que Google las apagará y en algunos casos desaparecerán automáticamente.

Al comienzo y por única vez vamos a crear una imagen del sistema operativo Ubuntu, con R y RStudio instalados, y todos los paquetes necesarios.

Esa imagen es la que van a utilizar siempre TODAS las máquinas virtuales.

Una máquina virtual esta definida por lo siguiente

- 1. La imagen del disco previamente creada (SO, programas instalados, configuraciones)
- 2. La cantidad de vCPU
- 3. La cantidad de memoria RAM
- 4. El tamaño del disco local ( que debe ser igual o superior al tamaño de la imagen )
- 5. La disponibilidad de la máquina virtual (Spot o normal)
- 6. La ubicación geográfica

Si se apaga y vuelve a encender una máquina virtual, sigue estando disponible lo que quedó en el disco local. Si se borra una máquina virtual, se pierde toda la información del disco local. Por la arquitectura de la solución, el disco local de las máquinas virtuales solamente se utiliza para almacenar información temporal que selectivamente es copiada al bucket de datos.

El bucket de datos, sería algo como un "disco de red" al que todas las máquinas virtuales pueden acceder, leer y escribir al mismo tiempo. También podemos manualmente subir información desde nuestras PCs por medio del Google Cloud Console.

Utilizamos el bucket de datos para:

- Almacenar los datasets, que son leídos por los programas R que corren en las máquinas virtuales. ~/buckets/b1/datasets
- Almacenar los resultados intermedios y finales de cada una de las corridas, ~/buckets/b1/exp

Es decir, en nuestra arquitectura la entrada y la salida siempre queda en el bucket. Se podría decir que la copia central del bucket está ubicada en USA.

La información del bucket de datos es persistente y totalmente independiente de las máquinas virtuales. Por más que se apague o incluso borre una máquina virtual, la información del bucket de datos permanece disponible, y es accesible por medio de Google Cloud Console. No hace falta que una máquina virtual esté encendida para acceder al contenido del bucket.

Va a ser muy común tener varias maquinas virtuales encendidas al mismo tiempo, cada una corriendo un *experimento* distinto en distintos datacenters del planeta, y todas ellas leyendo y escribiendo simultáneamente del mismo bucket de datos.

## Los pasos de este instructivo son :

- 1. Instalar lenguajes y entornos (se hace por única vez)
  - 1. Disclaimer (1 min)
  - 2. Habilitar Compute Engine API (1 min)
  - 3. Elegir idioma inglés (1 min)
  - 4. Habilitar Service Usage API (1 min)
  - 5. Crear máquina virtual inmortal (10 min)
  - 6. Ingresar a la terminal de la máquina virtual (1 min)
  - 7. Verificar versión de Ubuntu (1 min)
  - 8. Crear el bucket por línea de comando (3 min)
  - 9. Instalar (60 minutos, corre desatendido)
- 2. Crear Imagen, templates y desktop (se hace por única vez)
  - 1. Archivo kaggle.json (3 min)
  - 2. Cambiar la clave (1 min)
  - 3. Verificar datasets (1 min)
  - 4. Verificar R (1 min)
  - 5. Verificar Rstudio (1 min)
  - 6. Verificar Jupyter Lab (1 min)
  - 7. Clonar el repositorio personal (4 min)
  - 8. Crear la imagen, templates y desktop (10 min)
  - 9. Configuración inicial ambiente gráfico GNOME (15 min)
- 3. Metodología de trabajo en Google Cloud
  - 1. Entendiendo qué genera costos en GC
  - 2. Aumentando el poder de cómputo asumiendo riesgos
  - 3. Disciplina de trabajo
  - 4. Crear máquina virtual desde template
  - 5. RStudio en forma remota
  - 6. Usar Jupyter Lab en forma remota
  - 7. Desde una terminal Ubuntu con la consola de R correr scripts
- 4. Cuando finalice la materia
  - 1. Evitar que Google Cloud facture

Instalación de lenguajes
y
entornos

## 1.1 Disclaimer

Este instructivo de instalación del entorno de trabajo en Google Cloud es relativamente fácil de seguir, sin embargo no aspire a entender lo que se está haciendo en cada paso y mucho menos a ser capaz de modificar o crear de cero los scripts de instalacion usted mismo.

No es la tarea de la asignatura ni tampoco de la maestría en Ciencia de Datos lograr que usted se transforme en un Data Engineer, Linux System Administrator o Cloud Architect. Para alguien sin conocimientos previos demandaría un curso de al menos 32 horas ser capaz de generar esta instalación, más unas 60 horas de práctica.

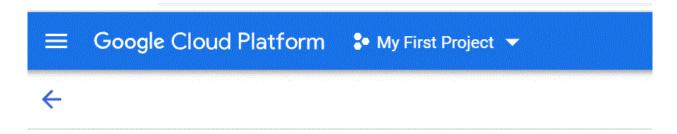
Usted si aprenderá a ser usuario de esta plataforma y entrenar los modelos predictivos necesarios para su tarea de Data Scientist.

No se angustie por simplemente seguir un instructivo.

## 1.2 Habilitar Compute Engine API

Ir a <a href="https://console.cloud.google.com/compute/instances">https://console.cloud.google.com/compute/instances</a>

Y si le aparece





presione el botón de **Enable**, y espere unos minutos

## 1.3 Elegir idioma inglés

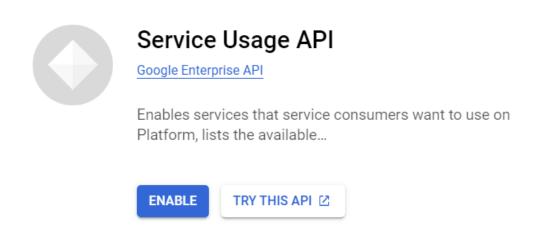
Ir a <a href="https://console.cloud.google.com/user-preferences/languages">https://console.cloud.google.com/user-preferences/languages</a> y elegir el idioma English( United States )

## 1.4 Habilitar Service Usage API

Ir a <a href="https://console.developers.google.com/apis/api/serviceusage.googleapis.com/">https://console.developers.google.com/apis/api/serviceusage.googleapis.com/</a>

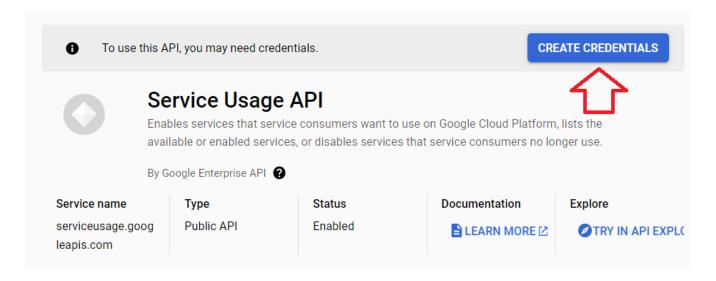
Y si le aparece

## Product details



presione el botón de **Enable**, y espere unos segundos

Luego presione el botón Create Credentials

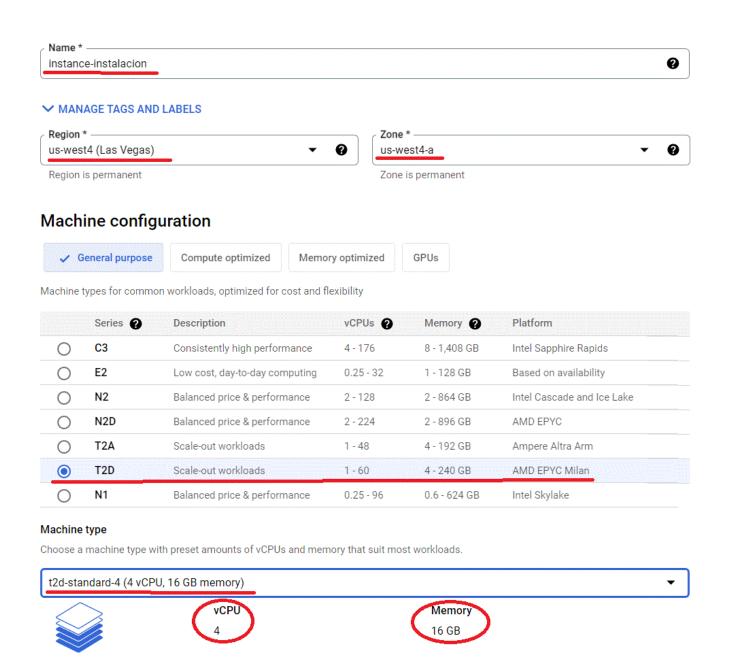


## API Create credentials 0 Credential Type Which API are you using? :7 Different APIs use different auth platforms and some credentia to only call certain APIs. =; Select an API \* -Service Usage API What data will you be accessing? \* Different credentials are required to authorize access dependin data that you request. Learn more 🗹 This Google Cloud API is usually accessed from a s 0 service account. To create a service account, select data". User data Data belonging to a Google user, like their email address or age. required. This will create an OAuth client. Application data Data belonging to your own application, such as your app's Clou This will create a service account. **NEXT** Your Credentials CANCEL

## 1.5 Crear Maquina Virtual

Por favor, prestar atención a todo lo que esté encerrado en una elipse roja, subrayado por una linea roja, o apuntado por una flecha roja en las impresiones de pantalla, es VITAL cumplir a rajatabla esa instrucción.

Una vez que ya se dio de alta en Google Cloud, ir a la página <a href="https://console.cloud.google.com/compute/instancesAdd">https://console.cloud.google.com/compute/instancesAdd</a>



## **✓ ADVANCED CONFIGURATIONS**

## Availability policies VM provisioning model Standard Choose "Spot" to get a discounted, preemptible VM. Otherwise, stick to "Standard". Learn more 🖸 Set a time limit for the VM ? On VM termination Choose what happens to your VM when it's preempted or reaches its time limit On host maintenance Terminate VM instance When Compute Engine performs periodic infrastructure maintenance it can migrate your VM instances to other hardware without downtime Automatic restart Compute Engine can automatically restart VM instances if they are terminated for non-user-initiated reasons (maintenance event, hardware failure, software failure and so on) **∧** VM PROVISIONING MODEL ADVANCED SETTINGS Display device Enable to use screen capturing and recording tools. Enable display device Confidential VM service @ Confidential Computing is disabled on this VM instance **ENABLE** Container @ Deploy a container image to this VM instance **DEPLOY CONTAINER**

En la elección del Boot Disk deberá seleccionar estas opciones.

Size (GB) \* -

32

Por favor, siga estas instrucciones al pie de la letra, cualquier otra alternativa a Ubuntu 22.04 LTS Minimal no funcionará, un tamaño menor a 32 GB de disco, fallará y dará crípticos mensajes de error.

# Select an image or snapshot to create a boot disk; or attach an existing disk. Can't find what you're looking for? Explore hundreds of VM solutions in Marketplace (2) PUBLIC IMAGES CUSTOM IMAGES SNAPSHOTS ARCHIVE SNAPSH Operating system Ubuntu Version \* Ubuntu 22.04 LTS Minimal x86/64, amd64 jammy minimal image built on 2023-07-26 Boot disk type \* Standard persistent disk COMPARE DISK TYPES

Por favor, es MUY IMPORTANTE que el disco tenga **32GB** de espacio, en caso contrario no se podrá instalar todo e inexplicables errores lo devorarán.

## Boot disk @

Name	New standard persistent disk		
Туре			
Size	32 GB		
License type ?	Free		
Image	Ubuntu 22.04 LTS Minimal		
Image	1 (1) (1) (1) (1) (1) (1) (1) (1) (1) (1		

CHANGE

## Identity and API access @

## Service accounts ?

Service account -

Compute Engine default service account

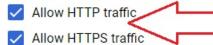
Requires the Service Account User role (roles/iam.serviceAccountUser) to be set for users who want to a account. Learn more ☑

## Access scopes ?

- Allow default access
- Allow full access to all Cloud APIs
- O Set access for each API

## Firewall @

Add tags and firewall rules to allow specific network traffic from the Internet



Allow Load Balancer Health Checks

## Observability - Ops Agent @

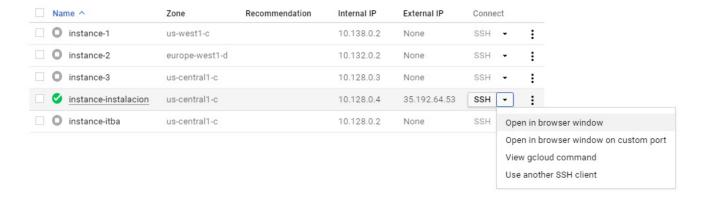
Monitor your system through collection of logs and key metrics.

Install Ops Agent for Monitoring and Logging

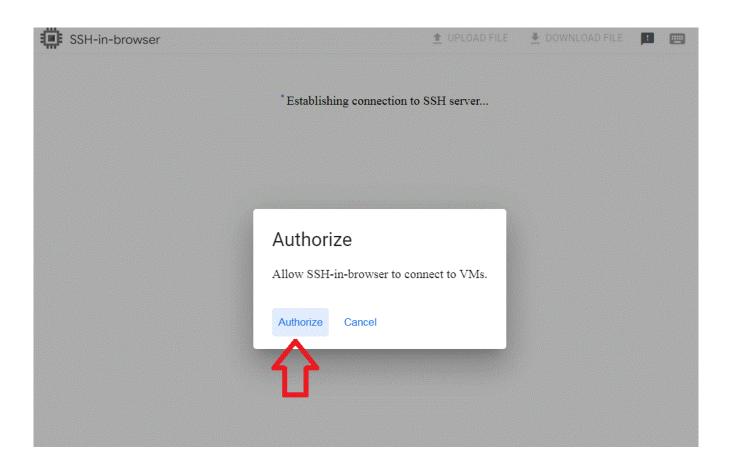
## Advanced options

Networking, disks, security, management, sole-tenancy

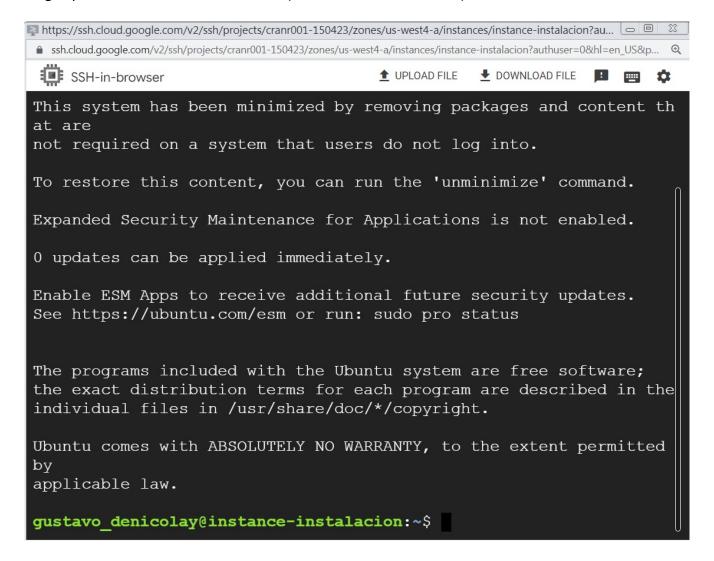
## 1.6 Ingresar a la terminal de la máquina virtual recién creada



primero aparecerá una ventana como esta donde deberá presionar el botón de



luego aparecerá una ventana como esta (con **su** nombre de usuario)



para futuras referencias, su usuario Ubuntu que aparece antes del arroba @, en el caso de la imagen anterior el nombre de usuario es : gustavo denicolay

Atención, es posible por problemas de internet al momento de ingresar a la máquina virtual presionando el botón de SSH, o levantar el archivo, le salga el siguiente mensaje de error:

Code: 1006

Please ensure you can make a proper https connection to the IAP for TCP

hostname https://tunnel.cloudproxy.app

You may be able to connect without using the Cloud Identity-Aware Proxy

En ese caso, espere unos minutos y vuelva a intentarlo.

## 1.7 Verificar versión de Ubuntu

En la imagen anterior debe aparecer

## This system has been minimized by removing packages and content that are

luego, desde la terminal Ubuntu escribir lo que está en color azul (dar Enter al final)

## \$ lsb\_release -a

le deberá aparecer

No LSB modules are available.

Distributor ID: Ubuntu

Description: Ubuntu 22.04.4 LTS

Release: 22.04 Codename: jammy

cualquier cosa distinta que le aparezca indica que usted ha cometido un error en el paso 1.3 porque eligió otra versión de Ubuntu (un error usual); debe eliminar la virtual machine instance-instalacion y crearla nuevamente

## 1.8 Crear bucket por línea de comandos

desde la terminal Ubuntu (dar enter al final)

```
$ gsutil mb gs://buko666
```

Donde buko666 debe ser un nombre único, no repetido en todo Google Cloud Si le aparece que ya existe ese nombre de bucket, volver a intentar el mismo comando con otro nombre de bucket

Si le sale el siguiente mensaje, es que debe elegir otro nombre y volver a correr el comando ServiceException: 409 A Cloud Storage bucket named 'buko666' already exists. Try another name. Bucket names must be globally unique across all Google Cloud projects, including those outside of your organization

Si por alguna razón usted debe volver a reinstalar, y ya creó el bucket, NO vuelva a crear otro!

## 1.9 Instalar

desde la terminal Ubuntu ejecutar estos tres comandos ( el \$ inicial en color negro representa el prompt de Ubuntu, y **no** debe ser tipeado )

```
$ wget https://storage.googleapis.com/open-courses/austral2024-fc72/instalar.sh -0 instalar.sh
$ chmod u+x *.sh
$ ./instalar.sh
```

Este paso es completamente automático, puede llevar alrededor de 65 minutos, se verán pasar decenas de miles de líneas por la pantalla; algunos alumnos manifestaron sentirse dentro de una Matrix pero es nada más que una humilde, aburrida y típica instalación Linux, la mayor parte del tiempo se compilan los paquetes de R.

Atención, ante cualquiera de estos desafortunados eventos

- se le corta internet durante la instalación
- se le apaga su PC
- su PC entra en modo ahorro de energía

se le cerrará la consola de Ubuntu y usted deberá volver a ingresar a la máquina virtual, botón SSH y una vez dentro de la terminal Ubuntu debe ejecutar el siguiente comando

```
$ tmux attach
```

e ingresará nuevamente a la instalación, la que habrá seguido corriendo por más que usted perdió conexión. NO ABANDONE JAMAS LA INSTALACION! APAGUE ESE MAQUINA VIRTUAL SI VA A CONTINUAR AL DIA SIGUIENTE Y COMIENCE DE CERO.

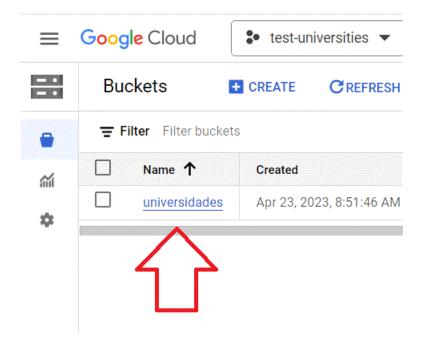
## Crear Imagen (del sistema operativo) templates y desktop

## 2.1 Archivo kaggle.json

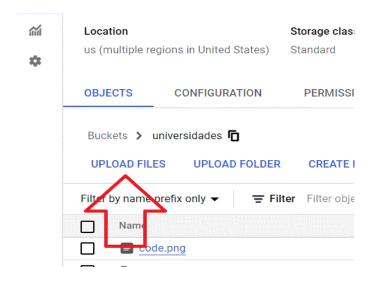
En el Libro de la Asignatura, usted se bajó el archivo kaggle.json a un lugar seguro en su laptop Ahora debe subirlo al bucket.

Estando en la consola de Google Cloud vaya a <a href="https://console.cloud.google.com/storage/browser">https://console.cloud.google.com/storage/browser</a>

Una vez allí dentro, haga click en el nombre de su bucket (le va a aparecer el nombre de su bucket, no la palabra universidades )



Dentro, vaya a UPLOAD FILES , busque el archivo en su laptop, y súbalo al bucket.



## 2.2 Cambiar la clave

desde la terminal

( el \$ inicial en color negro representa el prompt de Ubuntu, y **no** debe ser tipeado )

Cambiar la clave

```
$ ~/cambiar_claves.sh
```

aparecerá en la pantalla "New password:", se debe tipear una password la que **no** es mostrada en pantalla mientras se va escribiendo (parece como que está todo "colgado"). Se debe presionar la tecla Enter al final. Luego solicita nuevamente la password.

Dado que es posible que en algún momento quiera compartir la máquina virtual con un compañero de equipo, se sugiere utilizar una password distinta a sus preferidas que utiliza en su HomeBanking. Se piden DOS passwords, una se utiliza para RStudio y la otra para Jupyter Lab, se sugiere que sean las mismas.

Con este usuario y password se ingresará al RStudio, <u>por favor recordar ambos</u> . Si comete un error, vuelva a correr el comando.

## 2.3 Verificar Datasets

corriendo desde la consola Ubuntu

\$ ls -1 ~/buckets/b1/datasets

se deberá observar los siguientes archivos

competencia\_2024.csv.gz

Ir a la página <a href="https://console.cloud.google.com/storage/browser">https://console.cloud.google.com/storage/browser</a> , hacer click en su bucket, luego en la carpeta datasets, y verificar que se ve el archivo.

## 2.4 Verificar R

Ejecutar el siguiente comando desde la terminal Ubuntu (la letra R debe estar en mayúsculas )

## \$ R

Le deberá aparecer la consola de R, corroborar el R version 4.3.3

```
R version 4.3.3 (2024-02-29) -- "Angel Food Cake"
Copyright (C) 2024 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.

> ■
```

para salir de esta pantalla, debe tipear quit( save="no") y luego la tecla Enter

## 2.5 Verificar RStudio

Ejecutar el siguiente comando desde la terminal Ubuntu

## \$ rstudio-server status

Le deberá aparecer algo de este estilo, donde es fundamental la parte en color verde active (running)

No de importancia a este tipo de mensajes, son simplemente hackers que intentan entrar a su máquina y no lo lograron

```
instance-instalacion rserver[42274]: ERROR Invalid method CONNECT requested
for uri: google
```

Sin embargo, SI es MUY IMPORTANTE lo siguiente:

Si no le aparece active(running), deberá hacer de nuevo la instalación, desde cero, GAME OVER.

Para salir presione la tecla "q"

## 2.6 Verificar Jupyter Lab

Ejecutar el siguiente comando desde la terminal Ubuntu

## \$ systemctl status jupyterlab

Le deberá aparecer algo de este estilo, donde es fundamental la parte en color verde active (running)

```
• jupyterlab.service - jupyterlab
Loaded: loaded (/etc/systemd/system/jupyterlab.service; enabled; vendor preset: enabled)
Active: active (running) since Tue 2024-03-12 00:07:03 UTC; 4min 9s ago
Main PID: 113381 (jupyter-lab)
Tasks: 1 (limit: 19168)
Memory: 72.3M
CPU: 1.513s
CGroup: /system.slice/jupyterlab.service
L113381 /usr/bin/python3 /home/gustavo_denicolay/.local/bin/jupyter-lab --no-brows
```

Si no le aparece active(running), deberá hacer de nuevo la instalación, desde cero, GAME OVER.

Para salir presione la tecla "q"

## 2.7 Clonar el repositorio personal

Esta es la parte más delicada de toda la instalación, proceda con gran cautela.

Usted debe clonar SU propio repositorio de GitHub, donde usted trabajará y hará modificaciones (no confundir con el repositorio oficial de la materia donde solo los profesores realizan cambios)

```
$ cd
$ git clone https://MariaLopez:token@github.com/MariaLopez/labo2024v1.git
$ cd labo2024v1
$ git config user.email "usted@gmail.com"
$ git config user.name "MariaLopez"
$ git remote add upstream https://github.com/labo-imp/labo2024v1.git
$ cd
```

es muy importante que luego del cd labo2024v1 verifique que efectivamente se encuentra en la carpeta labo2024v1 (se observa viendo el prompt), esto le indicará que la sentencia que comienza con git clone https:// ha funcionado bien.

## debe reemplazar

- MariaLopez por <u>su</u> nombre de usuario en GitHub
- token por el token que creó cuando accedió por primera vez a GitHub y que como decía el Libro de la Asignatura guardó en un lugar seguro. Si hubiera olvidado guardarlo deberá crear un nuevo token en GitHub, siguiendo los pasos de El Libro de la Asignatura, el que coexistirá con el primero que creó.
- usted por su dirección de gmail, (va con las comillas como está)

## 2.8 Crear la imagen, templates y desktop

Esta instrucción creará la imagen, los templates, y apagará la máquina ( el \$ inicial en color negro representa el prompt de Ubuntu, y **no** debe ser tipeado )

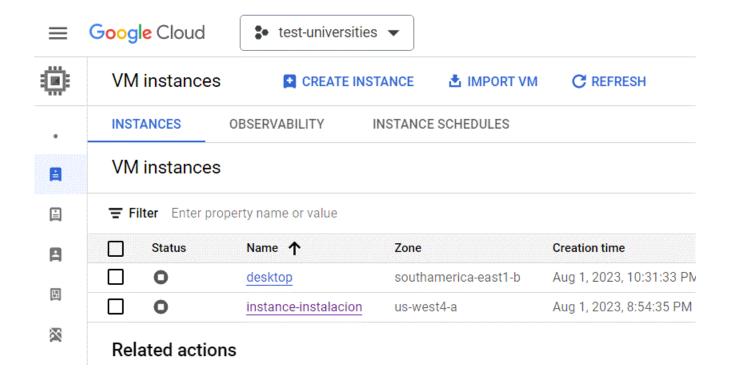
## \$ ~/final.sh

espere a que corra el comando unos 10 minutos, le aparececera "Presione la tecla Enter para finalizar..." presione Enter, se apagará la máquina virtual y su consola de Ubuntu se pondrá gris, con un mensaje de "Connection Failed", cierre esa ventana.

Ha finalizado la instalación, ya está en condiciones de procesar en Google Cloud, en nuevas máquinas virtuales.

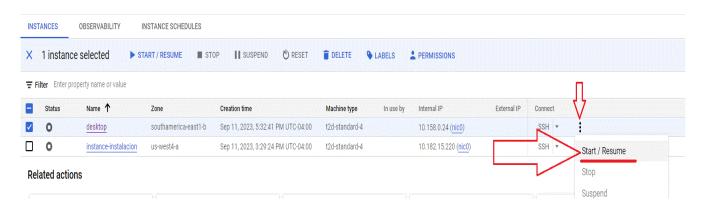
Espere a que el profesor le indique cuando es prudente eliminar instance-instalacion

Finalmente, usted tendrá 2 máquinas virtuales apagadas. Deberá ver algo parecido a esto:



## 2.9 Configuración inicial ambiente gráfico GNOME

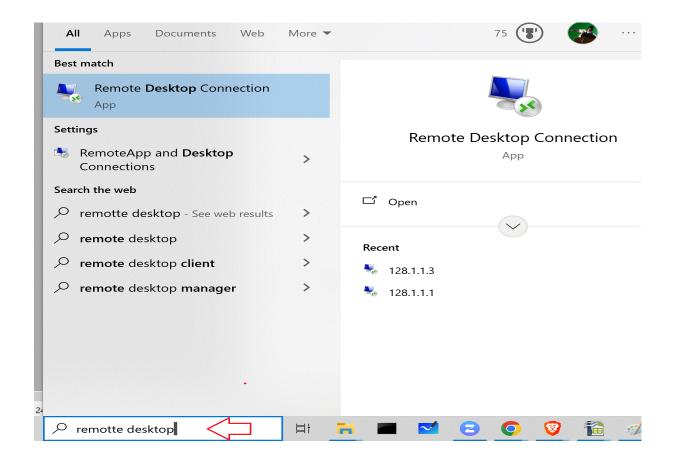
Vaya a <a href="https://console.cloud.google.com/compute/instances">https://console.cloud.google.com/compute/instances</a> y de Start/Resume a la virtual machine desktop



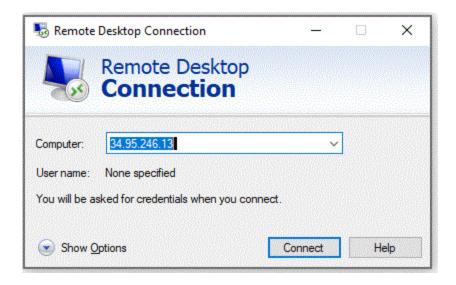
Una vez encendida la virtual machine, copie la External IP al portapapeles (debe posicionar el mouse donde señana la flecha roja)



Luego, desde la Search Bar de Windows busque la aplicación Remote Desktop Connection

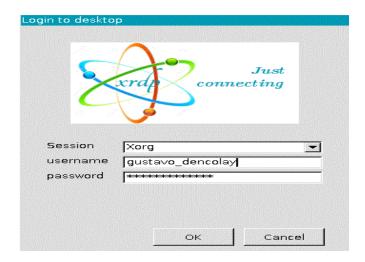


ingrese a la misma, y copie la External IP con Control + V

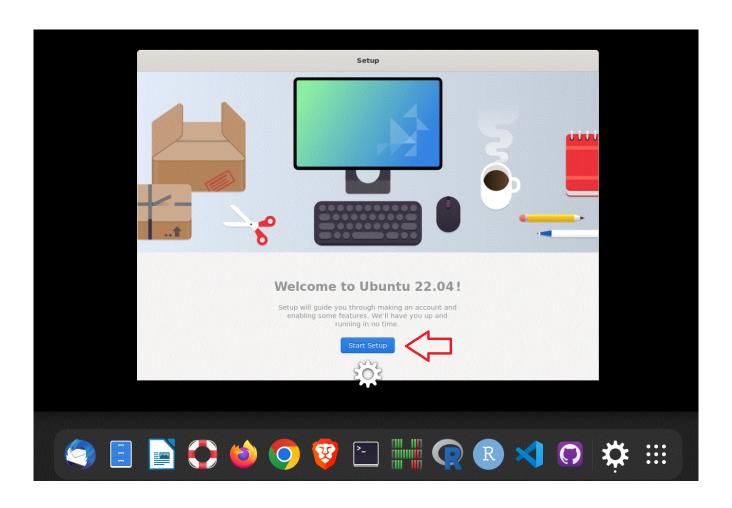


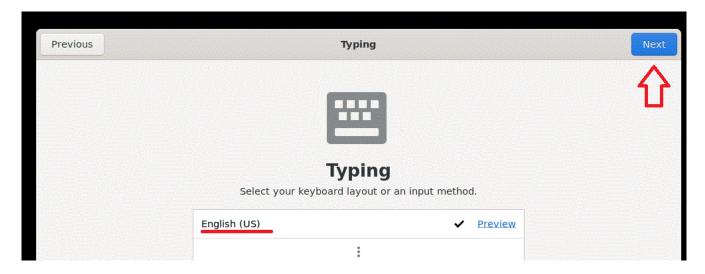
presione el boton connect en la siguiente pantalla pequeña que la aparece, hasta llegar a otra pantalla, donde deberá cargar el usuario y clave que especificó al momento de correr

## ./cambiar\_claves.sh



finalmente, ingresará a una pantalla como la que sigue, donde deberá presionar el boton azul Start Setup y recorrer las dos pantallas que siguen eligiendo su tipo de teclado

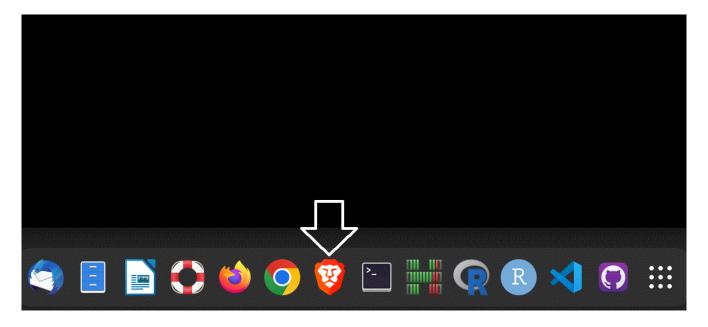




y de Next a la siguiente pantalla que le aparezca sobre Privacy sin cambiar nada (no se muestra la pantalla)

Finalmente presione el boton azul que dice Start Using Ubuntu (no se muestra la pantalla)

Maximice la pantalla del Remote Desktop y presione la tecla Windows de su teclado, se le desplagará en la parte inferior de la pantalla el menu de GNOME llamado dash, presione el botón del browser Brave con el mouse (un solo click)



luego de unos segundos se desplegará una pantalla que le pedirá, por única vez, una clave para el keyring, escriba la misma que eligió para Ubuntu

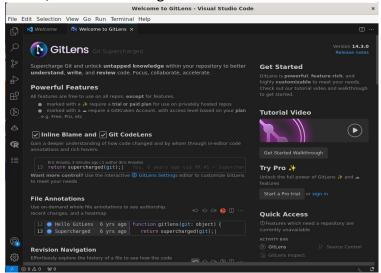


una vez que se abra el browser Brave ingrese, en este orden a

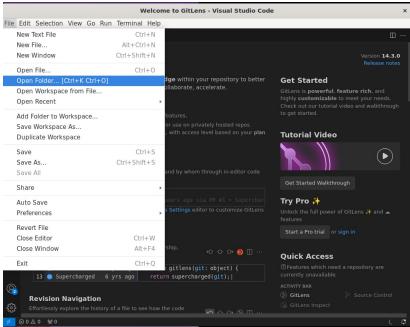
- 1. Su gmail
- 2. A su cuenta GitHub
- 3. A su cuenta Kaggle

tenga presente que seguramente Google le envíe un mensaje a su teléfono movil, ya que estará sorprendido que estando usted en Buenos Aires quiera conectarse de Sao Paulo (no se muestran las pantallas)

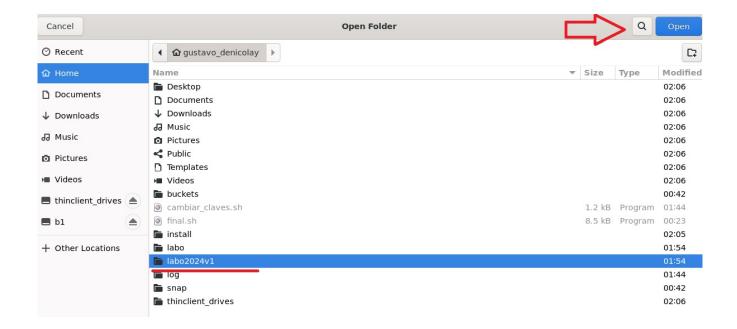
Vuelva a presionar el botón de Windows de su teclado para que se desplique el dash de GNOME, e ingrese al Visual Studio Code, deberia ver lo siguiente



## Vaya a File, Open Folder

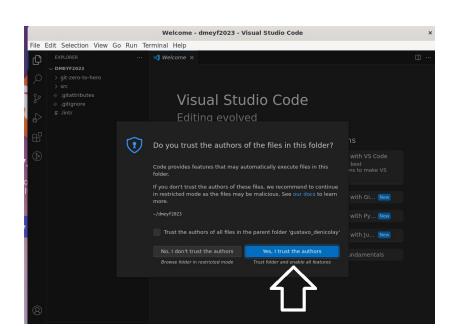


## Elija la carpeta que es el nombre del repositorio, y presione el boton azul Next



## En la siguiente pantalla presione el boton

Yes, I trust the authors



Enhorabuena, usted ya está en condiciones de trabajar.

Por ahora, no haga nada más, la virtual machine desktop entrará a los 15 minutos en modo Suspensión

En la clase presencial se le mostrará como trabajar en el ambiente con VSCode.

## Metodología de trabajo en Google Cloud

## 3.1 Entendiendo qué genera costos en GC

## ¿ Qué genera costo en Google Cloud?

Se paga aunque el proceso haya terminado.

Máquina Virtual ENCENDIDA, en función de la cantidad de vCPU, memoria RAM, tipo de disco local SSD o normal, tamaño disco local reservado, trafico de red saliente real, accesos a disco reales, costo del Sistema Operativo si este es pago ( Windows, Linux Red Hat ), zona donde es creada .

Se paga aunque no se esté procesando nada .

Máquina Virtual APAGADA, en función del espacio en disco alocado del sistema operativo y datos locales. Es adicional a la imagen.

Almacenar en discos SSD es muy costoso, aunque no se estén utilizando.

Bucket, espacio en disco realmente utilizado, GB por segundo en los que existieron los archivos.

Transferencias salientes del Bucket a otros lugares, ya sea lecturas desde máquinas virtuales en otras regiones de Google, o hacia PCs que residen fuera de Google.

Imágenes de discos según la cantidad de GB de disco utilizada, por más que ninguna máquina virtual esté utilizando dicha imagen.

https://cloud.google.com/compute/all-pricing?hl=en\_US&\_ga=2.249918022.-1998581785.1564797469

En cualquier momento usted puede verificar su consumo accediendo a <a href="https://console.cloud.google.com/billing">https://console.cloud.google.com/billing</a> y luego hacer click en el link que muestra la cuenta de facturación.

# 3.2 Aumentando el poder de cómputo asumiendo riesgos

Google busca constantemente su propio beneficio tentando a sus clientes para luego facturar más de lo que ellos esperan.

Esta es la historia detrás de los USD 300 gratuitos que duran un máximo de 3 meses, y una forma de "ganarle" a Google.

El uso de los USD 300 tiene ciertas restricciones, que son estas <a href="https://cloud.google.com/free/docs/gcp-free-tier">https://cloud.google.com/free/docs/gcp-free-tier</a>

Es decir, tiene la limitación que solo se pueden tener corriendo al mismo tiempo 8 vCPU, ya sean todas en una sola máquina virtual o distribuidas a lo largo de varias.

#### Aquí hay dos alternativas:

1) Crear una máquina virtual con solo 8 vCPU y vivir en un mundo completamente seguro y feliz, donde jamás Google les va a cobrar nada, y lo único que va a pasar es que una vez consumidos los USD 300 se les borren las máquinas virtuales creadas y particularmente el bucket con todos los datos que tengan dentro, con todas las salidas de las Optimizaciones Bayesianas.

Es un mundo completamente protegido, que no requiere de atención, solo es necesaria paciencia para esperar a que terminen los procesos.

Una máquina de 16vCPU no funciona 2 veces más rápido que una de 8 vCPU, el escalamiento del procesamiento NO ES LINEAL, ya que los programas por más que estén escritos para correr en paralelo, hay partes inevitables que corren en forma secuencial.

- 2) Hacer algo más arriesgado que necesita un monitoreo diario:
- 2.1) Darle autorización a Google para que cuando se pasen de los USD 300, empiece a cobrar. De esa forma podrán crear tener corriendo más de 8 vCPU al mismo tiempo.
- 2.2) Controlar en forma diaria cuántos USD van gastando, y al llegar a los USD 270, apagar todas las máquinas virtuales y borrarlas, bajarse los datos que quieran del bucket, borrar el Bucket, borrar la imagen del sistema operativo, es decir dejar sin nada cosa que lo que google Cloud quiera cobrarles por mes sea CERO.

En este caso les quedará la cuenta quizás con USD 15 a favor , y no les cobrará nada jamás. El umbral de USD 270 es porque hay un delay de alrededor de 24 horas entre el consumo que muestra Google Cloud en la página versus el real que terminará facturando.

El punto 2) implica estar alerta, y revisar todo el tiempo el consumo, en particular cuando se pone una máquina grande a funcionar.

Si el alumno no tiene un computer literacy adecuado y no tiene una férrea disciplina de control es preferible que opte por la opción 1) (lo que tiene actualmente), para vivir más tranquilo en un

mundo seguro y feliz. Después de todo, se puede perfectamente hacer todo con 8 vCPU, a lo sumo se esperan más horas.

Aclaración importante, Google corre un algoritmo para detectar a personas que probablemente luego de terminado el periodo gratis jamás paguen por nuevos servicios, y en esos casos NO permite pasar de las 8 vCPU. No está claro cómo funciona este algoritmo.

Adicionalmente, alumnos han reportado haber sido contactados por Atención al Cliente de Google Cloud, en donde les hacen una campaña preventiva de retención de clientes, intentando lograr que luego de agotar los USD 300 pasen al modo pago y se transformen en clientes reales.

Jamás ha sido reportado por un alumno el evento que Google les bloquee definitivamente una cuenta.

Todos los años, sucede con probabilidad 0.02 (1 en 50), que un alumno pasó al modo desprotegido, no controla diariamente si se olvidó una máquina virtual inmortal encendida, se pasa de los USD 300 gratuitos, y Google le factura a su tarjeta. En la gran mayoría de estos casos han podido revertirlo implorando piedad a Google haciéndose pasar por desvalidos estudiantes de un país del tercer mundo que no entiende muy bien que es la nube y que solo obedecía ordenes de una cátedra...

### 3.3 Disciplina de trabajo

- Usted tiene su propio repositorio hosteado en GitHub
- Si usted tiene un avanzado computer literacy y ya conoce GitHub, se las arreglará solo, y no siga leyendo este capítulo de Disciplina de trabajo.
- En caso contario, usted trabajará en una máquina virtual Ubuntu con interfase gráfica llamada desktop que se encuentra en el datacenter de Google Cloud en San Pablo, Brasil.
- Todos los scripts y archivos de experimentos se desarrollan (escriben y/o modifican) desde VSCode en la máquina virtual desktop, y deberá mantener constantemente sincronizado su repositorio en desktop con su repositorio en GitHub
- Se hará una demostración completa en clase de la forma de trabajo.
- La máquina virtual solamente se utiliza para desarrollar, para correr scripts grandes deberá hacerlo en nuevas máquinas virtuales
- Para cada nueva corrida, cada optimización bayesiana, se procede de esta forma:
  - Se modifican los scripts en la máquina virtual gráfica desktop
  - Sincroniza los repositorios
  - Se crea una nueva máquina virtual a partir de los templates
  - Se ingresa al RStudio de esa máquina virtual
  - Se pone a correr el experimento desde Rstudio de la máquina virtual
  - De ninguna forma usted puede verse tentado a hacer un cambio de último momento en el script y que eso no quede reflejado en el repositorio GitHub, hay decenas de casos de buenas corridas que no se han podido volver a reproducir por no haber guardado la versión del script que corrió.
  - Se espera unos minutos para ver que levantó bien el dataset y empezó a escribir en los logs
  - Un tema delicado es saber si usted le asignó la suficiente cantidad de memoria RAM a su máquina virtual. Luego de lanzar a correr su experimento desde el RStudio, puede ingresar a la terminal Ubuntu, correr el comando htop y monitoree el uso de memoria RAM los primeros minutos.
  - Toda optimización Bayesiana sobre varios meses demandará al menos 128GB de memoria RAM, y si trabaja con datasets con mas de mil atributos necesitará 256 GB de RAM. Si la memoria RAM es insuficiente, deberá BORRAR esa máquina virtual y volver a crear otra con EL DOBLE DE MEMORIA; no sea tacaño, ir subiendo de apenas unos pocos GB para probar es caminar sobre espinas.
  - Monitorear periódicamente que la máquina virtual spot no fue apagada por Google y que además de estar encendida nuestro experimento continúa corriendo (se puede monitorear desde la app de Google Cloud Console para móviles en caso que desee hacerlo un sábado a la noche desde un local bailable)
  - Si la máquina se apagó y eliminó, usted debe volver a crear la misma máquina, y poner a

- correr nuevamente el experimento, los experimentos están diseñados para retomar la Optimización Bayesiana desde donde había quedado.
- Podría llegar a suceder que sea de día en ese datacenter, se estén utilizando todos los recursos, y usted vea que la máquina virtual no se enciende, o se apaga enseguida. En este caso, va a tener que eliminarla, y crear una nueva en otro datacenter de Google.
- Si la máquina está encendida pero el experimento ya no está corriendo verifique si ha sido tan afortunados que su proceso ya terminó.
- Si el proceso abortó por algún error, primero debe prepararse un café bien cargado y luego empezará la batalla por entender el motivo y como corregirlo.
- Si dejó corriendo un experimento durante la noche, al despertar verifique su estado.
- Una vez que está todo terminado, se verifican que existan los archivos de salida.
   apagar la máquina virtual
- o verificar que realmente quedó apagada, que no está el tilde verde
- eliminar la máquina virtual. Por favor, no reutilice las máquinas virtuales, solo encontrará angustia y sufrimiento; para cada corrida debe crear una nueva máquina virtual.
- Verifique que la máquina virtual ya no aparece en VM Instances. Una máquina virtual apagada continúa consumiendo dinero, ya que Google cobra por el espacio de disco local.
- Desestime la recomendación de Google de aumentar la cantidad de vCPU, ellos ven que su proceso está al 100% de uso de CPU y solo quieren facturarle más. Toda corrida suya de optimización de hiperparámetros siempre estará al 100% independientemente de cuantas vCPU asigne a esa máquina virtual.

#### No le de importancia a estos warnings

#### [LightGBM] [Warning] No further splits with positive gain, best gain: -inf

(simplemente está diciendo que no puede construir un nuevo árbol de decisión en el ensemble ya que no son lo suficientemente buenos)

[LightGBM] [Warning] Auto-choosing col-wise multi-threading, the overhead of testing was 0.962394 seconds.

You can set `force col wise=true` to remove the overhead.

(simplemente está informando sobre una optimización)

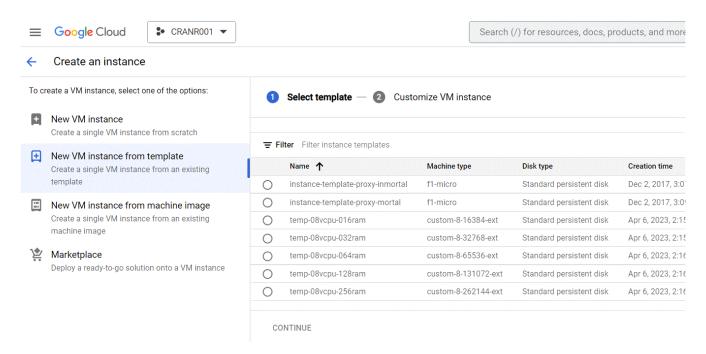
[LightGBM] [Warning] verbosity is set=-1, verbose=-1 will be ignored. Current value: verbosity=-1 (no hay ningún tipo de problema)

aprenda a convivir con warnings, NO TEMA

### 3.4 Crear una Maquina Virtual desde template

Ingrese al link https://console.cloud.google.com/compute/instancesAdd?
creationFlow=fromTemplate

verá algo similar a esto:



Elija la máquina virtual que se adapte a la memoria RAM que requiere el script que va a correr. Para todos los scripts diseñados para correr en Google Cloud la cátedra ha comentado al comienzo del mismo la cantidad de memoria RAM que requiere, en la medida que utilice un dataset de dimensiones similares. Si usted le ha agregado al dataset cientos de atributos adicionales, deberá elegir una máquina virtual con más memoria RAM.

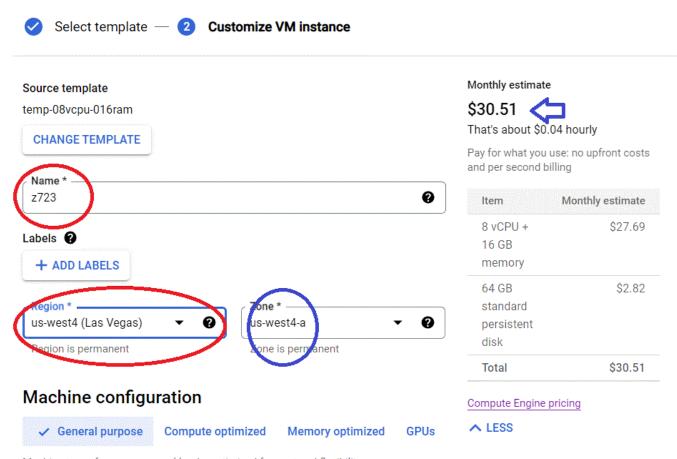
Luego de elegir un template, presione el botón CONTINUE

en la siguiente pantalla debe elegir

- Name nombre de la máquina virtual (generalmente el script que va a correr)
- Region
- Zone

Usted debe buscar una Region de forma que el costo, ese dia a esa hora, sea lo menor posible. Generalmente Las Vegas es el menor costo.

La Zone depende de la Region, y todas las Zone de la misma Region tienen el mismo costo. Una Region es un edificio distinto dentro del mismo predio al que llaman Zone, que es donde está el datacenter.



Machine types for common workloads, ontimized for cost and flevihility

Finalmente dar al boton Create que está al final del formulario, y volver a la página <a href="https://console.cloud.google.com/compute/instances">https://console.cloud.google.com/compute/instances</a> que es donde verá encenderse su máquina virtual.

Para ingresar a RStudio o Jupyter Lab pase a los siguientes capítulos

Nota para alumnos avanzados: los templates que están creados tienen todos 8 vCPU y la memoria RAM va de 16GB a 256GB. Es posible que en las últimas semanas usted se vea tentado a crear máquinas virtuales con más vCPU para acelerar, aunque sea algo, los procesos.

Si usted desea crear templates con otras configuraciones, debe ir a <a href="https://console.cloud.google.com/compute/instanceTemplates/">https://console.cloud.google.com/compute/instanceTemplates/</a> <a href="mailto:add">add</a> y tener en cuenta lo siguiente

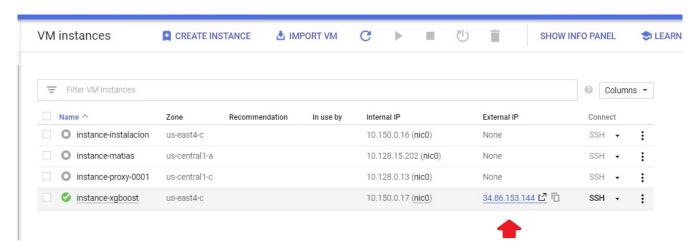
- En name elija un nombre nemotécnico para su template
- En Series debe elegir N1, en Machine type Custom, debe marcar el recuadro Extended Memory
- Elija los Cores y Memory que desea
- En Boot disk debe ir a la solapa CUSTOM IMAGES y elegir image-dm , en Boot disk type elija Standard Persistent Disk, en Size el doble de la memoria RAM que eligió (se va a encontrar con el limite de 300GB)
- En Access scopes elija Allow full access to all Cloud APIs
- En Firewall marque ambas opciones Allow HTTP traffic y Allow HTTP traffic
- Lo MAS IMPORTANTE, en Advanced Options / Management / VM provisioning Model elegir Spot , y en Advanced Options / Management / On VM termination elegir Delete .

### 3.5 RStudio en forma remota

RStudio fue configurado para trabajar con el puerto 80, de forma de poder ser utilizado detrás del firewall de una universidad, empresa, cafetería, etc

Para RStudio se debe utilizar el usuario y claves vistos en el punto "2.1 asignar password al usuario".

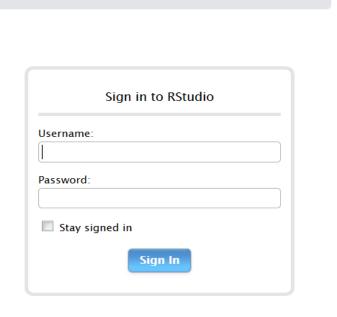
La forma de ingresar al RStudio copiando la dirección External IP (pública)



y en el browser poner  $\underline{\text{http:}//34.86.153.144/}$  notar que dice http SIN la letra "s" al final (en este ejemplo utilicé mi IP pública, reemplazarla por la que le aparece a usted)

y se abrirá en el browser de la PC local la página de ingreso al RStudio

R Studio



Es muy importante notar, que el acceso a RStudio es mediante una conexión insegura del tipo http:// y NO mediante la conexión segura de https:// , hay alumnos que utilizan laptops corporativas y esto les ha generado imposibilidad de acceso.

Una vez dentro, navegar a la carpeta del repositorio labo buscar el script, y comenzar a ejecutarlo.

Dentro de Rstudio, ir a la solapa Terminal , que es la terminal de Ubuntu, y allí correr el comando htop el que mostrará el uso de CPU y memoria RAM. Lo importante a controlar es el Swap , aparece debajo de la memoria como Swp , si pasa de cero y las CPU estan con muy poco uso por mas de un minuto, entonces quiere decir que se creó una máquina virtual con insuficiente memoria RAM para ese <script, dataset> ; debe eliminarse esa marquina virtual , crear una nueva con el doble de memoria y volver a correr el script.

### 3.6 Jupyter Lab en forma remota

Desde el navegador de la PC local, utilizando la External IP (pública) de la máquina virtual escribir http://35.44.55.66:8888/lab

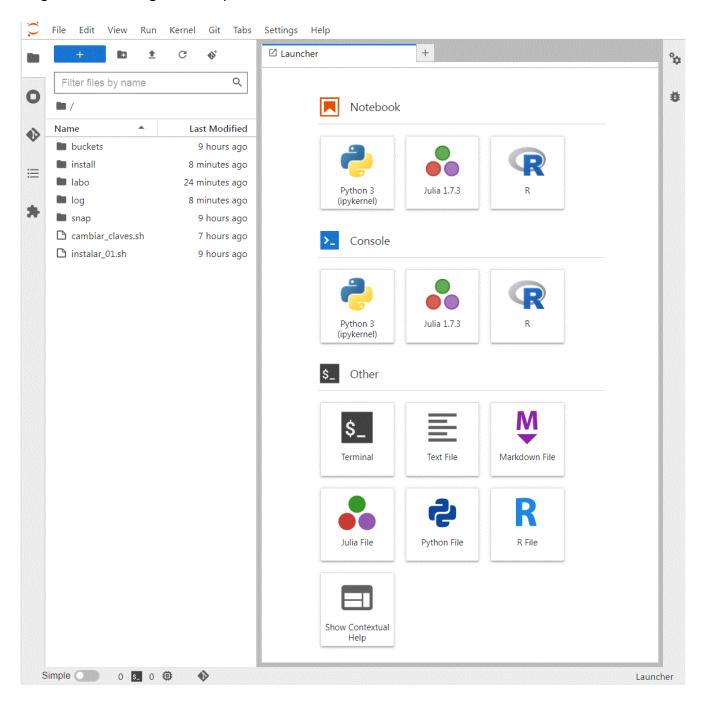
#### (reemplazar lo rojo el la IP que corresponda)

notar aquí lo mismo, es también una conexión insegura del tipo http:// ya que NO funciona con la letra "s" al final, o sea https:// . Lamentablemente la conexión a Jupyter Lab se realiza por el puerto 8888 el que podría estar bloqueado por su empleador.

La primer pantalla que aparece le solicita la clave de Jupyter Lab, que la definió en cambiar\_claves y casi con seguridad es la misma que la de RStudio



#### luego de unos 20 segundos le aparecerá



Dentro de JupyterLab navegar dentro de la carpeta labo hasta donde este el notebook que se desea ejecutar, cargarlo, y ejecutarlo

### 3.7 Desde una terminal Ubuntu con la consola de R correr scripts

No vaya por este camino a menos que usted tenga más de 3000 ( tres mil ) horas de experiencia en programación generadas en los últimos 5 años.

Esta es una forma de muy bajo nivel para correr un script, se le recomienda permanecer en la zona de confort del RStudio y su hermosa y segura interfase gráfica.

En primera instancia se debe abrir la terminal Ubuntu

luego, para correr desde la terminal se debe tipear (es una sola línea )

```
$ nohup Rscript --vanilla ~/labo/src/rpart/z101_PrimerModelo.R &
```

( decididamente vanilla ni es un script ni un paquete de R )

# 4 Cuando Finalice la Materia

# 4.1 Evitar que Google Cloud facture

Para que Google Cloud jamás le facture nada, al finalizar la materia se debe proceder de la siguiente forma :

- · Borrar todas las imágenes de disco creadas
- Borrar todos los datos dentro de los Buckets creados ( o el único Bucket que se creó )
- Eliminar todos los Buckets creados
- Apagar todas las máquinas virtuales creadas
- Eliminar todas las máquinas virtuales creadas
- En caso de haber creado algún otro objeto en Google Cloud que no fue mencionado en la materia, eliminarlo .